Compilador para a linguagem de programação T++

Jorge L. F. Rossi[1]

[1]Departamento de Computação – Universidade Tecnológica Federal do Paraná (UTFPR)
Caixa Postal 071 – 87.301-899 – Campo Mourão – PR – Brasil

jorgerossi@alunos.utfpr.edu.br

Abstract. *In the implementation of a compiler, the first step to be performed is Lexical Analysis, where the source code is separated into a set of tokens, which will be used in the future as input to the Syntactic Analysis process. library. This second step consists in checking if the input source code structure follows the formal grammar specified for the language, generating a tree structure as output, which will be used later in the Semantic Analisys and Code Generation steps. In Semantic Analysis, it is verified if the program follows the rules sensitive to the language context, and a table of symbols is assembled. Finally, if the program is semantically correct, in the Code Generation step an intermediate LLVM code is generated, which can be made into an executable. This paper describes all the steps in building a compiler for the T ++ programming language, using Python in conjunction with PLY[Beazley] library.*

Resumo. *Na implementação de um compilador, a primeira etapa a ser realizada é a Análise Léxica, onde o código fonte é separado em um conjunto de tokens, os quais serão utilizados futuramente como entrada no processo da Análise Sintática. Essa segunda etapa consiste em verificar se a estrutura do código fonte de entrada segue a gramática formal especificada para a linguagem, gerando uma estrutura de árvore como saída, a qual será utilizada posteriormente nas etapas de Análise Semântica e Geração de Código. Na Análise Semântica, é verificado se o programa segue as regras sensíveis ao contexto da linguagem, além de ser montada uma tabela de símbolos. Por fim, se o programa estiver semanticamente correto, na etapa da Geração de Código é gerado um código intermediário LLVM, o qual pode ser transformado em um executável. Este trabalho descreve todas as etapas na construção de um compiladorpara a linguagem de programação T++, utilizando Python em conjunto com a biblioteca PLY.*

1. Introdução

Este trabalho descreve a especificação da linguagem de programação T++, utilizada para estudo durante a disciplina. Trata-se de uma linguagem simples contendo comandos em português. Tem suporte a dois tipos básicos de dados (inteiro e flutuante), funções e procedimentos, operadores aritméticos, operadores lógicos, vetores unidimensionais e um laço de repetição. Serão apresentados em detalhes cada classe de *token* disponível na linguagem, bem como os respectivos autômatos. Também serão listadas a descrição da gramática no padrão BNF, bem como uma discussão sobre qual o formato utilizado pela ferramenta na Análise Sintática. Além disso, será descrito o funcionamento de uma implementação da análise léxica e sintática utilizando a linguagem *Python* e a biblioteca

PLY, juntamente com exemplos de saída do sistema de varredura. Por fim, serão descritos os passos da Análise Semântica e Geração de Código, contendo informações sobre a tabela de símbolos e o código intermediário gerado, respectivamente.

2. Especificação da linguagem

A linguagem T++ se baseia em comandos em português, tendo suporte a dois tipos de dados (inteiro e flutuante). É possível criar funções e procedimentos (funções sem retorno) além da função principal. Permite o uso de operadores lógicos e aritméticos básicos, além de ter suporte a vetores unidimensionais e a um laço de repetição.

2.1. Lista de palavras reservadas

`se, então, senão, repita, até, fim, retorna, leia, escreva, flutuante, inteiro`

2.2. Lista de operadores

`+ (soma), - (subtração), * (multiplicação), / (divisão), = (igual), <> (diferente), < (menor), > (maior) <= (menor ou igual) >= (maior ou igual), := (atribuição), && (e), || (ou), !  (não)`

2.3. Exemplo de código

(Bubble Sort)

```
inteiro: vet[10]
inteiro: tam

tam := 10

{ preenche o vetor no pior caso }
preencheVetor()
  inteiro: i
  inteiro: j
  i := 0
  j := tam
  repita
    vet[i] = j
    i := i + 1
    j := j - 1
  até i < tam
fim

{ implementação do bubble sort }
bubble_sort()
  inteiro: i
  i := 0
  repita
    inteiro: j
    j := 0
    repita
      se vet[i] > v[j] então
```

```
        inteiro: temp
        temp := vet[i]
        vet[i] := vet[j]
        vet[j] := temp
      fim
      j := j + 1
    até j < i
    i := i + 1
  até i < tam
fim

{ programa principal }
inteiro principal()
  preencheVetor()
  bubble_sort()
  retorna(0)
fim
```

3. Lista de *tokens*

Os tokens foram separados em categorias, sendo estas: palavras reservadas, operadores aritméticos, operadores lógicos, operadores de atribuição, constantes, identificadores, símbolos e comentários.

3.1. Palavras reservadas

As palavras reservadas (*keywords*) são palavras que controlam a estrutura do programa, não sendo possível utilizá-las como nome de variáveis ou funções.

- *Token:* SE
- Expressão regular: `se`
- Autômato:

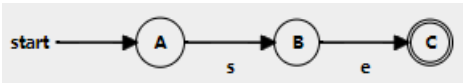

- *Token:* ENTAO
- Expressão regular: `então`
- Autômato:

- *Token:* SENAO
- Expressão regular: `senão`
- Autômato:

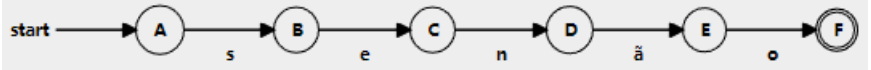

- *Token:* REPITA
- Expressão regular: `repita`
- Autômato:

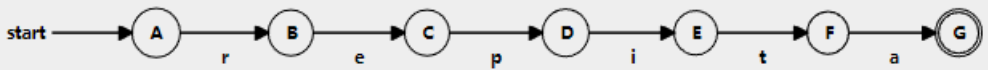

- *Token:* ATE
- Expressão regular: `até`
- Autômato:

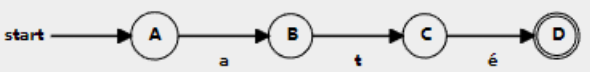

- *Token:* FIM
- Expressão regular: `fim`
- Autômato:

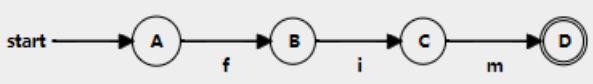

- *Token:* RETORNA
- Expressão regular: `retorna`
- Autômato:

- *Token:* LEIA
- Expressão regular: `leia`
- Autômato:

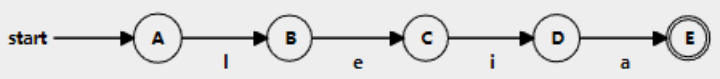

- *Token:* ESCREVA
- Expressão regular: `escreva`
- Autômato:

- *Token:* FLUTUANTE
- Expressão regular: `flutuante`
- Autômato:

- *Token:* INTEIRO

- Expressão regular: `inteiro`
- Autômato:

3.2. Operadores Aritméticos

Operações matemáticas básicas

- *Token:* SOMA
- Expressão regular:
- Autômato:

- *Token:* SUBTRACAO
- Expressão regular:
- Autômato:

- *Token:* MULTIPLICACAO
- Expressão regular:
- Autômato:

- *Token:* DIVISAO
- Expressão regular:
- Autômato:

3.3. Operadores Lógicos

Operações lógicos básicos

- *Token:* IGUALDADE
- Expressão regular: =
- Autômato:

- *Token:* DESIGUALDADE
- Expressão regular: <>

- Autômato:

- *Token:* MENOR
- Expressão regular: <
- Autômato:

- *Token:* MENOR_IGUAL
- Expressão regular: <=
- Autômato:

- *Token:* MAIOR
- Expressão regular: >
- Autômato:

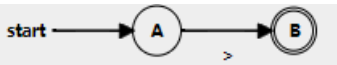

- *Token:* MAIOR_IGUAL
- Expressão regular: >=
- Autômato:

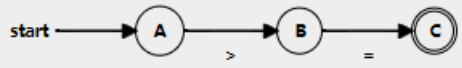

- *Token:* E_LOGICO
- Expressão regular: \&\&
- Autômato:

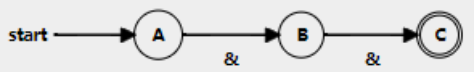

- *Token:* OU_LOGICO
- Expressão regular: \|\|
- Autômato:

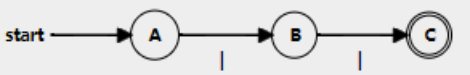

- *Token:* NEGACAO
- Expressão regular: !
- Autômato:

3.4. Operadores de Atribuição

Somente um operador básico de atribuição

- *Token:* ATRIBUICAO
- Expressão regular: `:=`
- Autômato:

3.5. Constantes

Números inteiros e de ponto flutuante.

- *Token:* NUM_INTEIRO
- Expressão regular: `(-|+)?[0-9]+`
- Autômato:

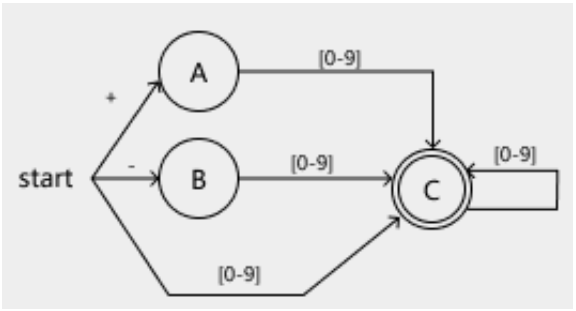

- *Token:* NUM_PONTO_FLUTUANTE
- Expressão regular: `(-|+)?[0-9]+.[0-9]*`
- Autômato:

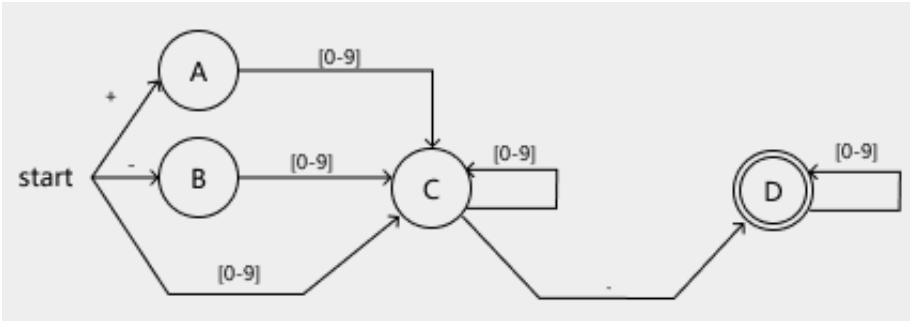

- *Token:* NUM_NOTACAO_CIENTIFICA
- Expressão regular:

```
(((-|+)?[0-9]+.[0-9]*)|((-|+)?[0-9]+))(e|E)(-|+)?[0-9]+
```

- Autômato:

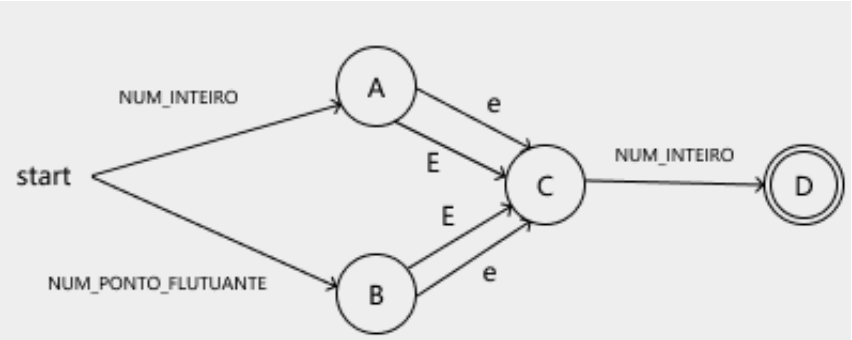

3.6. Identificadores

Variáveis e funções.

- *Token:* IDENTIFICADOR
- Expressão regular:
  `[A-Za-záàâãéèêíïóôõöúçñÁÀÂÃÉÈÍÏÓÔÕÖÚÇÑ]`
  `[0-9A-Za-záàâãéèêíïóôõöúçñÁÀÂÃÉÈÍÏÓÔÕÖÚÇÑ_]*`
- Autômato:

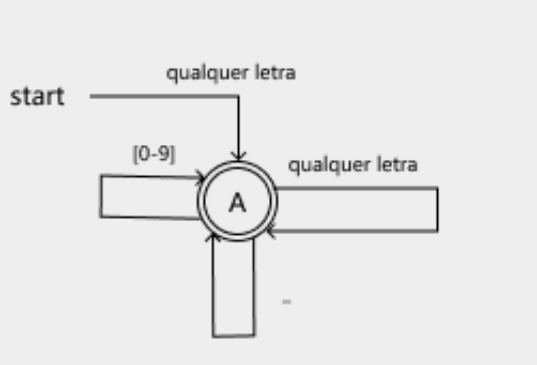

3.7. Símbolos

Símbolos diversos.

- *Token:* VIRGULA
- Expressão regular: `,`
- Autômato:

- *Token:* DOIS_PONTOS
- Expressão regular: `:`
- Autômato:

- *Token:* ABRE_PAR
- Expressão regular: (

- Autômato:

- *Token:* FECHA_PAR
- Expressão regular:)
- Autômato:

- *Token:* ABRE_COL
- Expressão regular: [
- Autômato:

- *Token:* FECHA_COL
- Expressão regular:]
- Autômato:

3.8. Comentário

Comentário de bloco

- *Token:* COMENTARIO
- Expressão regular: $\{[\hat{\}}]*[\hat{\}]*\}$
- Autômato:

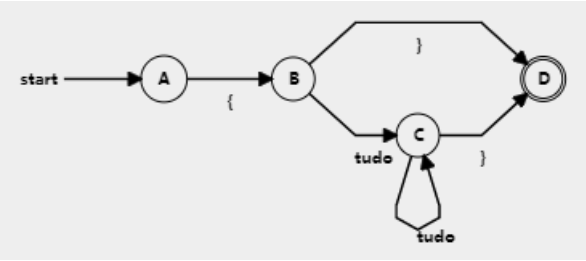

4. Descrição da Gramática no padrão BNF

O Formalismo de Backus-Naur (BNF) é uma sintaxe utilizada para expressar gramáticas livres de contexto, sendo amplamente utilizada como notação para as gramáticas de linguagens de programação. A seguir se encontra a BNF utilizada na implementação da linguagem T++.

```
programa ::=
lista_declaracoes

lista_declaracoes ::=
lista_declaracoes declaracao
| declaracao

declaracao ::=
declaracao_variaveis
| inicializacao_variaveis
| declaracao_funcao

declaracao_variaveis ::=
tipo DOIS_PONTOS lista_variaveis

inicializacao_variaveis ::=
atribuicao

lista_variaveis ::=
lista_variaveis VIRGULA var
| var

var ::=
ID
| ID indice

indice ::=
indice ABRE_COL expressao FECHA_COL
| ABRE_COL expressao FECHA_COL

tipo ::=
INTEIRO
| FLUTUANTE

declaracao_funcao ::=
decltipo cabecalho
| cabecalho

cabecalho ::=
ID ABRE_PAR lista_parametros FECHA_PAR corpo FIM
```

```
lista_parametros ::=
lista_parametros VIRGULA parametro
| parametro
| vazio

parametro ::=
tipo DOIS_PONTOS ID
|  parametro ABRE_COL FECHA_COL

corpo ::=
corpo acao
| vazio

acao ::=
expressao
| declaracao_variaveis
| se
| repita
| leia
| escreva
| retorna
| erro

se ::=
SE expressao ENTAO corpo FIM
| SE expressao ENTAO corpo SENAO corpo FIM

repita ::=
REPITA corpo ATE expressao

atribuicao ::=
var ATRIBUICAO expressao

leia ::=
LEIA ABRE_PAR var FECHA_PAR

escreva ::=
ESCREVA ABRE_PAR expressao FECHA_PAR

retorna ::=
RETORNA ABRE_PAR expressao FECHA_PAR

expressao ::=
expressao_logica
| atribuicao
```

```
expressao_logica ::=
expressao_simples
| expressao_logica operador_logico expressao_simples

expressao_simples ::=
expressao_aditiva
| expressao_simples operador_relacional expressao_aditiva

expressao_aditiva ::=
expressao_multiplicativa
| expressao_aditiva operador_soma expressao_multiplicativa

expressao_multiplicativa ::=
expressao_unaria
| expressao_multiplicativa operador_multiplicacao expressao_unaria

expressao_unaria ::=
fator
| operador_soma fator
| operador_negacao fator

operador_relacional ::=
MENOR
| MAIOR
| IGUALDADE
| DESIGUALDADE
| MENOR_IGUAL
| MAIOR_IGUAL

operador_soma ::=
SOMA
| SUBTRACAO

operador_logico ::=
E_LOGICO
| OU_LOGICO

operador_negacao ::=
NEGACAO

operador_multiplicacao ::=
MULTIPLICACAO
| DIVISAO

fator ::=
ABRE_PAR expressao FECHA_PAR
```

```
| var
| chamada_funcao
| numero

numero ::=
NUM_INTEIRO
| NUM_PONTO_FLUTUANTE
| NUM_NOTACAO_CIENTIFICA

chamada_funcao ::=
ID ABRE_PAR lista_argumentos FECHA_PAR

lista_argumentos  ::=
lista_argumentos VIRGULA expressao
| expressao
| vazio
```

5. Detalhes da implementação

5.1. Análise Léxica

O analisador léxico da linguagem T++ foi desenvolvido utilizando a linguagem de programação Python, em conjunto com a biblioteca PLY (Python Lex-Yacc), uma implementação das ferramentas *lex* e *yacc*. Foi utilizada uma abordagem orientada a objetos na construção do analisador.

Primeiramente, foram definidas as palavras reservadas, bem como quais *tokens* as mesmas geram. O PLY requer que seja especificado uma lista com todos os *tokens* disponíveis na linguagem a ser desenvolvida, juntamente com as expressões regulares relacionadas. Alguns tipos de *tokens* necessitam de um tratamento especial, por exemplo:

- Ao encontrar um comentário, pular a linha.
- Ao encontrar um identificador, verificar se é uma palavra reservada.
- Ao encontrar um número, converte-lo para o tipo adequado.

Para os demais tipos de *tokens* não é necessário nenhum tratamento especial, bastando definir as expressões regulares que os geram.

5.2. Análise Sintática

No analisador sintático da linguagem T++ também foi utilizada a biblioteca PLY. A partir da BNF especificada da linguagem foram criadas funções para reconhecerem as regras, as quais também vão criando nós em uma estrutura de árvores que por fim é exportada para ser visualizada na forma de um grafo. Foi implementada uma classe básica *Node* para armazenar cada nó.

Um exemplo de regra implementada utilizando o YACC encontra-se a seguir:

```
def p_programa(self, p):
    '''programa : lista_declaracoes'''
    p[0] = Node('programa', [p[1]])
```

O código acima indica para o YACC encontrar uma produção do tipo *lista_declaracoes*. Ao encontrar, monta um nó na árvore sintática do tipo *programa* contendo as produções a direita como filhos.

Segundo a documentação da biblioteca, é utilizado o formato LR ou shift-reduce na Análise Sintática. Essa técnica se baseia na abordagem `bottom up`, a qual procura reconhecer a parte à direita das regras gramaticais. Quando uma entrada válida for encontrada, os símbolos gramaticais são substituídos pelos símbolos encontrados à direita. O algorítmo necessita de uma pilha, os *tokens* de entrada e uma tabela de parsing.

5.3. Análise Semântica

O analisador semântico foi implementado utilizando uma abordagem recursiva. A partir da árvore sintática gerada no passo anterior, todos os nós são percorridos e são realizadas diversas verificações para garantir que o programa está semanticamente correto. Foram criadas classes para descrever as variáveis e funções encontradas, contendo informações como: nome, tipo, escopo e dimensões. Foram criadas funções auxiliares conforme necessário, como adicionar uma chamada de função ou uma variável à tabela. Após realizadas as verificações, é realizada uma poda na árvore sintática abstrata, também utilizando uma abordagem recursiva. A árvore resultante tem é equivalente a árvore original, porém sem os nós intermediários.

6. Exemplo de execução

O programa a seguir lê um número a partir do teclado, calcula seu fatorial e mostra o resultado na tela.

```
inteiro: n
inteiro fatorial(inteiro: n)
    inteiro: fat
    se n > 0 então {não calcula se n > 0}
        fat := 1
        repita
            fat := fat * n
            n := n - 1
        até n = 0
        retorna(fat) {retorna o valor do fatorial de n}
    senão
        retorna(0)
    fim
fim

inteiro principal()
    leia(n)
    escreva(fatorial(n))
    retorna(0)
fim
```

Após a execução da Análise Léxica, o programa resultou na seguinte lista de *tokens* como saída. O nome entre colchetes se refere ao tipo de *token* identificado pelo analisador léxico. O segundo valor é o conjunto de caracteres que resultou no *token*.

```
[INTEIRO] inteiro
[DOIS_PONTOS] :
[ID] n
[INTEIRO] inteiro
[ID] n
[ATRIBUICAO] :=
[ID] n
[SUBTRACAO] -
[NUM_INTEIRO] 1
[ATE] até
[ID] n
[IGUALDADE] =
[NUM_INTEIRO] 0
[RETORNA] retorna
[ABRE_PAR] (
[ID] fat
[FECHA_PAR] )
[SENAO] senão
[RETORNA] retorna
[ABRE_PAR] (
[NUM_INTEIRO] 0
[FECHA_PAR] )
[FIM] fim
[FIM] fim
[INTEIRO] inteiro
[ID] principal
[ABRE_PAR] (
[FECHA_PAR] )
[LEIA] leia
[ABRE_PAR] (
[ID] n
[FECHA_PAR] )
[ESCREVA] escreva
[ABRE_PAR] (
[ID] fatorial
[ABRE_PAR] (
[ID] n
[FECHA_PAR] )
[FECHA_PAR] )
[RETORNA] retorna
[ABRE_PAR] (
[NUM_INTEIRO] 0
[FECHA_PAR] )
[FIM] fim
```

Após a execução da Análise Sintática, foi gerada a seguinte árvore de saída (a quantidade de nós se deve as regras intermediárias utilizadas durante o processo).

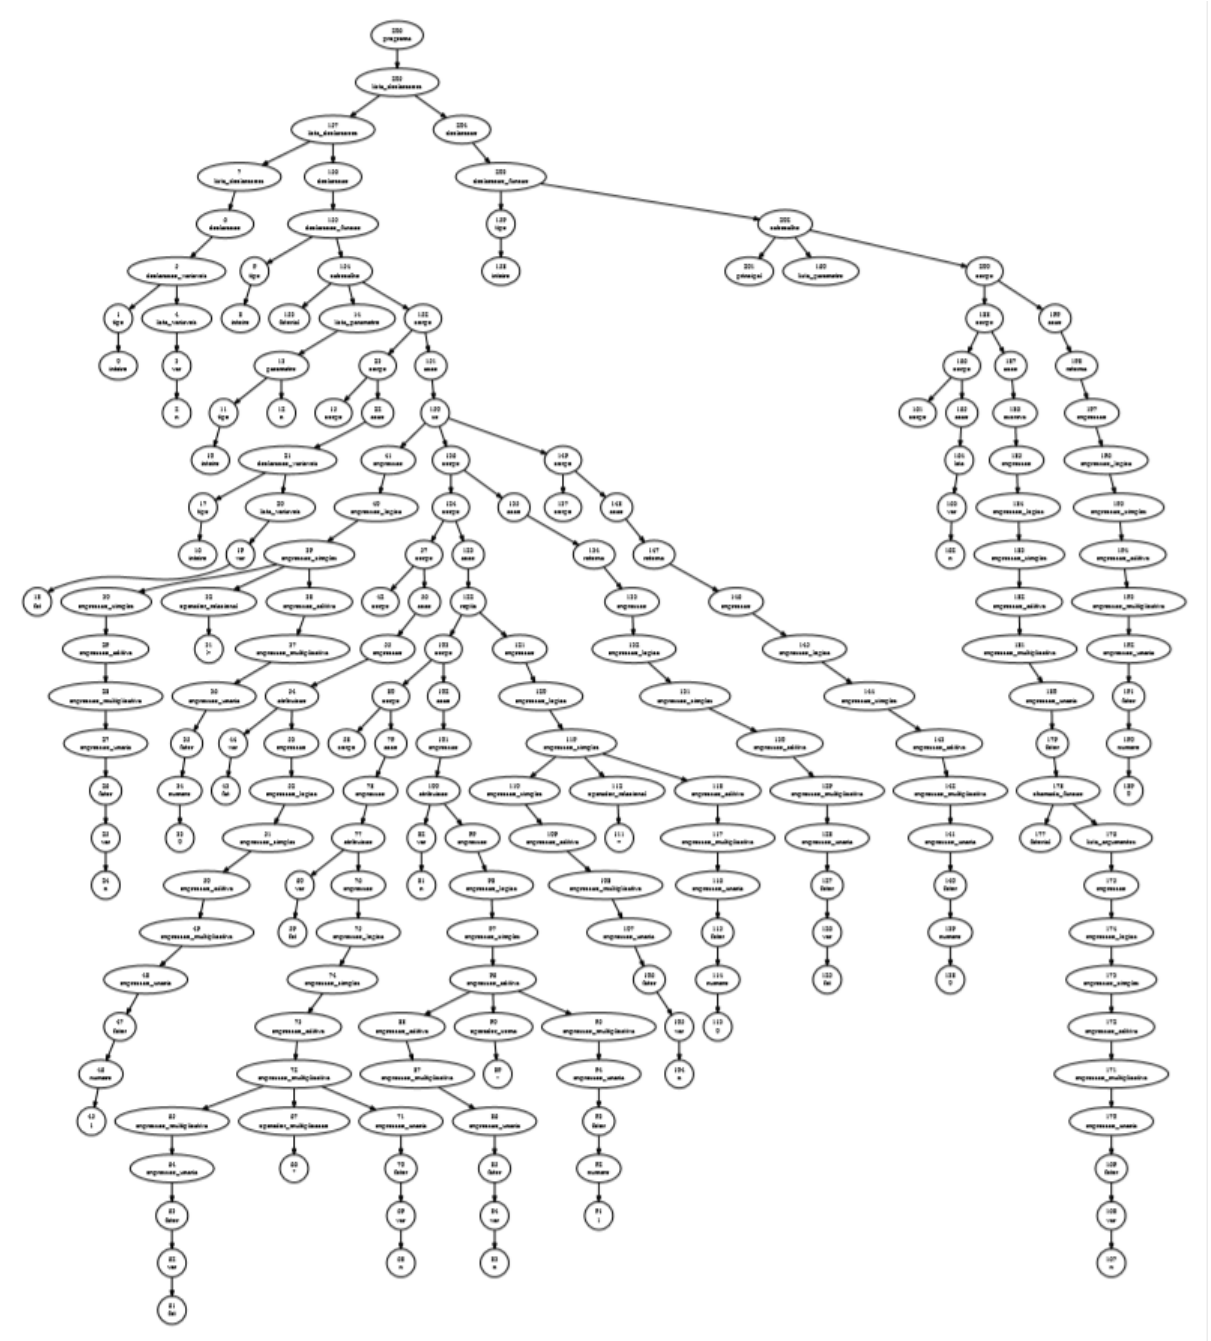

Exemplo de saída da Análise Semântica contendo os erros e a tabela de símbolos:

```
====================
Executando análise semântica...

Aviso: Variável ‘n’ declarada e não inicializada.
Aviso: Variável ‘n’ declarada e não utilizada.
Aviso: Variável ‘fat’ declarada e não utilizada.
Erro: Função ‘fatorial’ deveria retornar inteiro, mas retorna vazio.

Funções:

Escopo    Tipo     Nome       Utilizado
--------  -------  ---------  -----------
@global   inteiro  fatorial   True
@global   inteiro  principal  True

Variáveis:

Escopo    Tipo     Nome      Dimensões  Inicializado    Utilizado    Parâmetro
--------  -------  ------  -----------  --------------  -----------  -----------
fatorial  inteiro  n                 0  False           False        True
@global   inteiro  n                 0  False           True         False
fatorial  inteiro  fat               0  False           False        False
```

Árvore sintática após a poda:

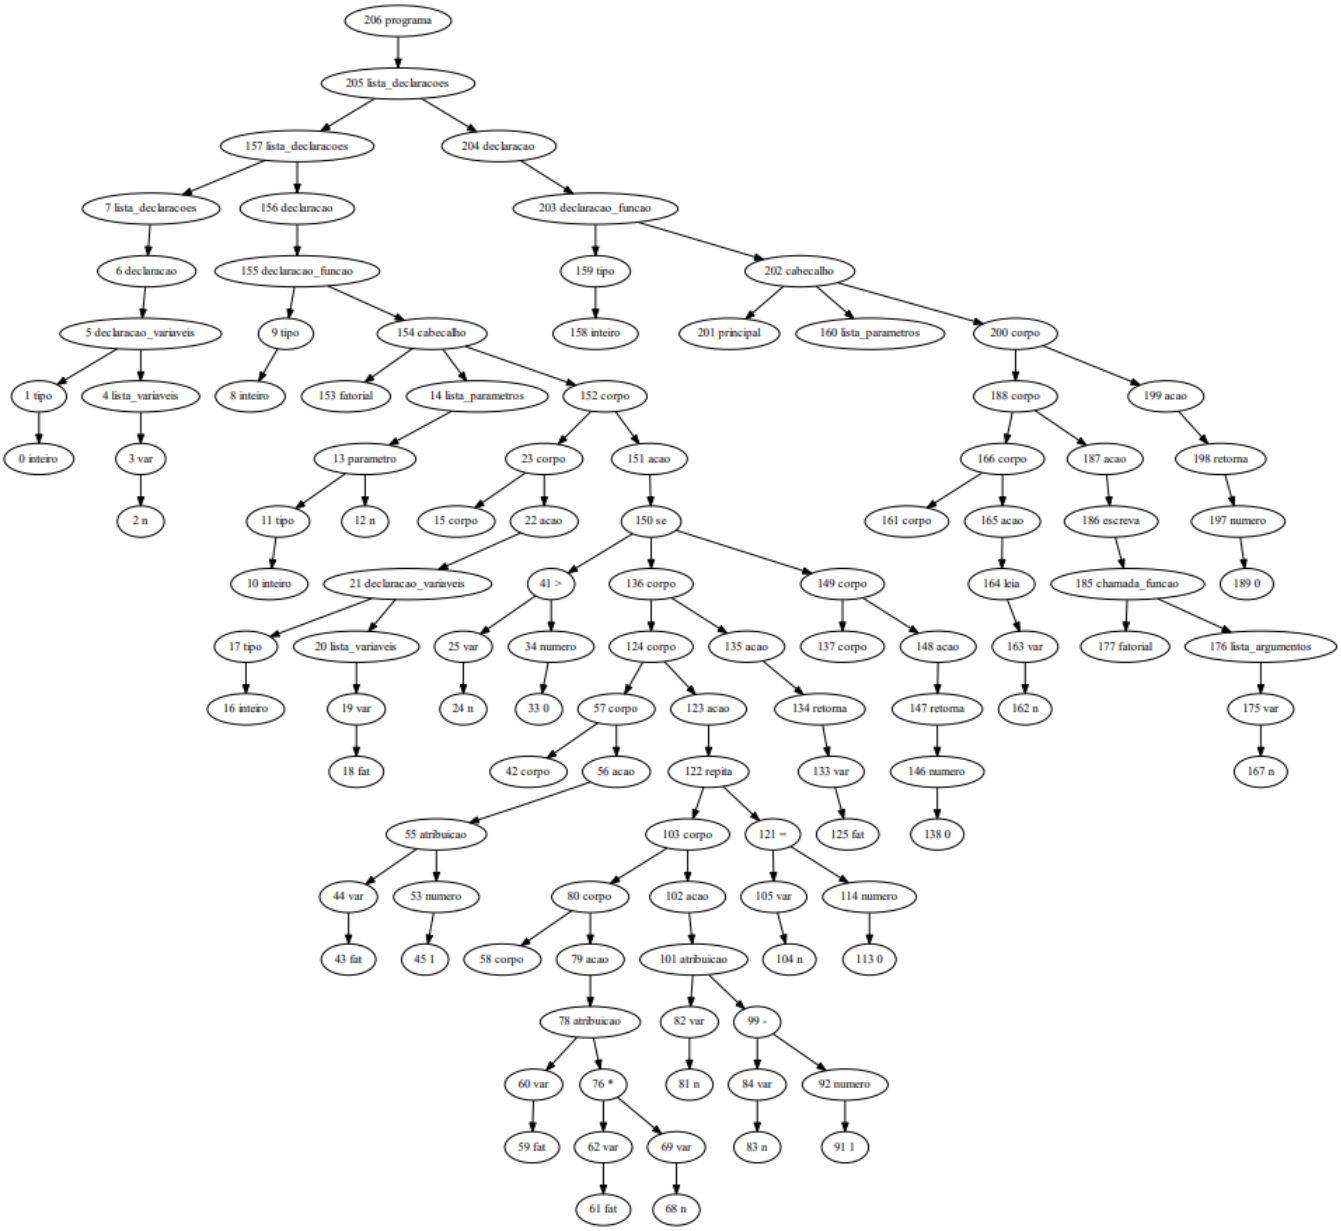

Referências

Beazley, D. M. Ply (python lex-yacc).